

نظام ذكاء صناعي لاكتشاف الأخبار الكاذبة باللغة العربية على منصة X

كلية الهندسة المعلوماتية
جامعة حمص
قسم الذكاء الاصطناعي

مشروع السنة الرابعة

إعداد الطلاب:
محمود الراعي
عبد السلام إبراهيم
بلال جوخدار
علي العباس
محمد الأبو حسنة

إشراف: الدكتور ناصر أبو صالح | العام الدراسي 2025-2026

فكرة المشروع ومشكلة البحث

تشكل الأخبار الكاذبة تهديدا متزايدا للمجتمعات في العصر الرقمي حيث تنتشر المعلومات المضللة بسرعة فائقة عبر منصات التواصل الاجتماعي وخاصة منصة X. وفقا لدراسة معهد ماساتشوستس للتكنولوجيا تنتشر الأخبار الكاذبة بسرعة أكبر بـ 6 مرات من الأخبار الحقيقية وتصل لعدد أكبر من الأشخاص بنسبة 70%. تزداد خطورة هذه الظاهرة في المحتوى العربي بسبب تعدد اللهجات وتعقيد بنية اللغة العربية صرفيا ونحويا ومحدودية مجموعات البيانات العربية الموسمة المتاحة للبحث العلمي.

يهدف هذا المشروع إلى تطوير نظام ذكاء صناعي متكامل قادر على الكشف التلقائي عن الأخبار الكاذبة باللغة العربية من خلال تحليل محتوى النصوص باستخدام تقنيات معالجة اللغات الطبيعية والتعلم العميق مع معالجة خاصة لتحديات اللغة العربية من تعدد لهجات وتشكيل واشتقاق وتعدد أشكال الهمزات.

أهداف المشروع

تطوير نظام ذكاء صناعي متكامل للكشف التلقائي عن الأخبار الكاذبة باللغة العربية بدقة عالية تتجاوز 85%. جمع وإعداد مجموعة بيانات عربية حقيقية ومتوازنة من الأخبار الصادقة والكاذبة. تطبيق تقنيات معالجة متقدمة للنصوص العربية تراعي تعدد اللهجات والتشكيل. بناء نموذج Baseline للمقارنة الموضوعية مع النموذج المتقدم. تطوير واجهة ويب تفاعلية تتيح للمستخدمين اختبار النظام بشكل عملي وفوري. المساهمة في سد فجوة بحثية حقيقية وتقديم أداة عملية لمكافحة المعلومات المضللة في المجتمع العربي.

المنهجية ومراحل العمل

نفذ المشروع على مدى أربعة أسابيع وفق منهجية متسلسلة. في الأسبوع الأول تم جمع البيانات وتجهيز بيئة التطوير. في الأسبوع الثاني تم تنظيف وتطبيع النصوص العربية وبناء نموذج Baseline باستخدام TF-IDF و Logistic Regression الذي حقق دقة أولية 60% فقط. في الأسبوع الثالث تم الانتقال إلى Google Colab للاستفادة من معالج رسومي Tesla T4 وموازنة البيانات وتدريب نموذج AraBERT المتقدم. وفي الأسبوع الرابع تم بناء واجهة الويب وربط النموذج بها واختبار النظام المتكامل وكتابة التوثيق النهائي.

اعتمد النظام على نموذج AraBERT aubmindlabbert-base-arabertv02 وهو نموذج BERT مدرب مسبقا على 24 جيجابايت من النصوص العربية تم ضبطه Fine-tuning باستخدام معدل تعلم 2e-5 وحجم دفعة 16 على مدى Epochs 3.

مجموعة البيانات

تم جمع مجموعة بيانات حقيقية تضم 46097 خبرا عربيا من مصادر إخبارية متنوعة سياسة صحة اقتصاد اجتماعية رياضة موزعة أصلا بين 42243 خبرا كاذبا و 3854 خبرا صادقا فقط أي بنسبة عدم توازن شديدة بلغت نحو 11 إلى 1. لمعالجة هذا الخلل تم أخذ عينة متوازنة من 6000 خبر صادق و 3000 كاذب قسمت إلى 80% للتدريب و 20% خبر للاختبار 1200 خبر. شملت المعالجة المسبقة إزالة الروابط والمنشئ والهاشتاغ والأرقام والتشكيل وتوحيد الهمزات وإزالة التظويل والرموز الخاصة.

الخدمات التي يقدمها النظام

تحليل أي نص خبري باللغة العربية وتصنيفه فوريا إلى صادق أو كاذب مع نسبة ثقة دقيقة. معالجة تلقائية للنصوص العربية تشمل إزالة الروابط والرموز والتشكيل وتوحيد الهمزات بما يتيح التعامل مع مختلف اللهجات المصرية الخليجية الشامية. واجهة ويب تفاعلية وسهلة الاستخدام تتيح للمستخدم إدخال النص أو اختيار مثال جاهز والحصول على النتيجة خلال أقل من ثانية واحدة.

عرض بصري واضح للنتيجة تلوين أخضر للأخبار الصادقة وأحمر للكاذبة مع شريط نسبة الثقة. معالجة شاملة للحالات الاستثنائية كالنصوص الفارغة أو القصيرة جدا أو الطويلة جدا.

التقنيات المستخدمة

- لغة البرمجة: Python 3.10
- نموذج الذكاء الاصطناعي: AraBERT aubmindlabbert-base-arabertv02
- مكتبات التعلم العميق: PyTorch Hugging Face Transformers
- نموذج المقارنة الأساسي: Logistic Regression + TF-IDF Scikit-learn
- تطوير الخادم: Backend: Flask Flask-CORS
- واجهة المستخدم: Frontend: HTML5 CSS3 JavaScript
- معالجة البيانات: Pandas NumPy pyarabic

معمارية النظام

يعتمد النظام على معمارية Client-Server ثلاثية الطبقات: طبقة عرض واجهة المستخدم بتقنيات HTMLCSSJavaScript وطبقة منطق أعمال خادم Flask يتولى تنظيف النصوص واستدعاء النموذج وطبقة ذكاء نموذج AraBERT و Tokenizer لإجراء التحليل والتصنيف. يتم تحميل النموذج مرة واحدة فقط عند بدء تشغيل الخادم ويبقى محفوظاً في الذاكرة ولا توجد قاعدة بيانات لأن النظام لا يحفظ استعلامات المستخدمين مما يحقق خصوصية كاملة للبيانات المدخلة.

أبرز النتائج

- الدقة: 99.67% Accuracy
- الدقة الإيجابية: 100% Precision
- الاستدعاء: 99.33%-100% Recall
- F1-Score: 99.67%
- زمن الاستجابة: نحو 500 ميلي ثانية
- حجم مجموعة البيانات المستخدمة: 6000 خبر متوازن من أصل 46097
- حجم النموذج: نحو 543 ميجابايت

أظهرت مصفوفة الارتباك على 902 عينة اختبار 449 حالة تصنيف صحيح لخبر كاذب و 450 حالة تصنيف صحيح لخبر صادق دون أي حالة اتهام خاطئ لخبر صادق بأنه كاذب False Positive ومع 3 حالات فقط من الأخبار الكاذبة التي مرت دون اكتشاف False Negative أي بنسبة خطأ إجمالية لا تتجاوز 0.33%.

الاختبار والتحقق

تم اختبار النظام على ثلاثة مستويات: اختبار النموذج على مجموعة الاختبار واختبار التكامل عبر عشرة سيناريوهات استخدام حقيقية أخبار كاذبة واضحة أخبار صادقة رسمية نصوص بلهجات عامية نصوص فارغة أو قصيرة جداً أو طويلة جداً واختبار الأداء لقياس زمن الاستجابة واستهلاك الموارد. حقق النظام نجاحاً تاماً في جميع السيناريوهات العشرة بمعدل نجاح 100% وتم التأكد من توافيقته مع متصفحات Chrome و Firefox و Edge و Safari.

التحديات والحلول

القيمة المضافة للمشروع

يقدم هذا المشروع حلاً عملياً متكاملًا وليس مجرد نتيجة أكاديمية حيث يجمع بين دقة تصنيف عالية جداً 99.67% وتطبيق ويب فعلي قابل للاستخدام الفوري باستجابة أقل من ثانية. كما يساهم المشروع في سد فجوة بحثية مهمة في مجال الكشف عن الأخبار الكاذبة العربية عبر معالجة تحديات تعدد اللهجات وعدم توازن البيانات وتعقيد اللغة العربية إلى جانب توثيق شامل لكامل منهجية العمل يجعل من هذا العمل مرجعاً يمكن البناء عليه مستقبلاً ليقدم بذلك أداة تقنية فعالة وقابلة للتطوير للمساهمة في مكافحة انتشار المعلومات المضللة في المجتمع العربي.

هيكلية النظام البرمجي

يتكون النظام من ملف خادم رئيسي app.py مبني بإطار عمل Flask يحتوي على دالة لتنظيف وتطبيع النصوص العربية ومسارين أساسيين لعرض الواجهة واستقبال التحليل إضافة إلى مجلد templates للواجهة الأمامية ومجلد منفصل يضم ملفات نموذج AraBERT المحفوظ و Tokenizer وأوزان النموذج. تم تصميم الكود بشكل معياري وواضح يسهل قراءته وصيانته وتوسيعه مستقبلاً مع تعليقات توضيحية باللغة العربية على الدوال الرئيسية.

آفاق التطوير المستقبلي

يمكن البناء على هذا المشروع مستقبلاً عبر عدة اتجاهات أبرزها: التكامل المباشر مع واجهة TwitterX API لتحليل المنشورات في الوقت الفعلي بدلاً من الإدخال اليدوي وإضافة تصنيف فرعي لأنواع الأخبار الكاذبة ساخرة دعائية مفبركة كلياً بدلاً من الاكتفاء بالتصنيف الثنائي ودمج تحليل ميتاداتا الحساب الناشر عمر الحساب عدد المتابعين سلوك النشر لتحسين الدقة في الحالات الحدية ونشر النظام على خادم سحابي عام ليصبح متاحاً لعموم المستخدمين بدلاً من العمل محلياً فقط وتطوير تطبيق هاتف محمول مرافق للتطبيق الحالي.

خاتمة

يمثل هذا المشروع نموذجا عمليا يوضح كيف يمكن لتقنيات الذكاء الاصطناعي الحديثة وتحديدًا نماذج Transformer المتخصصة باللغة العربية مثل AraBERT أن تسهم بفعالية حقيقية في مواجهة إحدى أبرز التحديات الرقمية المعاصرة. وبفضل الدقة الاستثنائية التي حققها النظام والتطبيق العملي الذي يرافقه يتجاوز هذا العمل حدود البحث الأكاديمي البحث ليقدّم أداة قابلة للاستخدام الفعلي تمثل لبنة أولى يمكن البناء عليها لتطوير حلول أوسع نطاقا لمكافحة الأخبار الكاذبة في المحتوى العربي.